Universidad Mariano Galvez
Ingeniería en Ciencia y Análisis de Datos
Programacion Avanzada
Katherine Michelle Santisteban Tejeda
Carne: 1113-19-1584

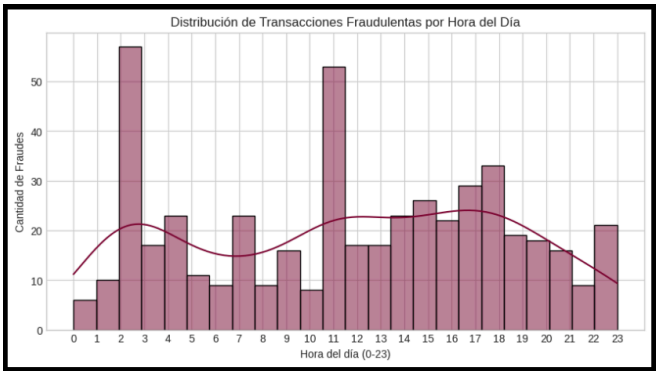
Exploración y fundamentos

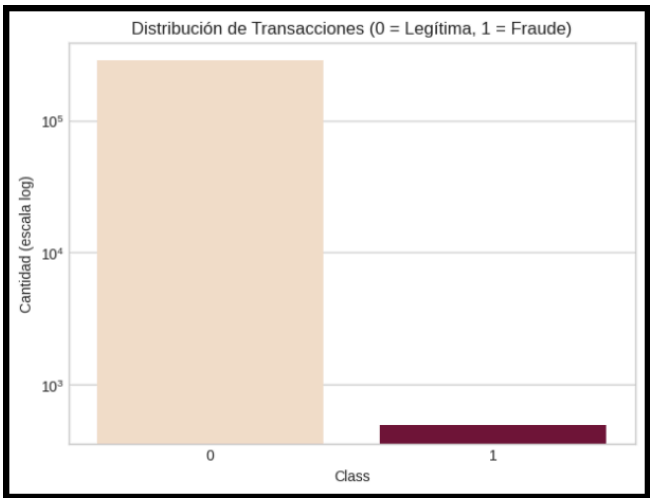
Enlace de Github: https://github.com/ksantistebant/bank

Carga de datos

Forma del dataset: (284807, 31)
Valores nulos totales: 0

Distribución de clases:
Class
0 284315
1 492
Name: count, dtype: int64
Porcentaje de fraude: 0.173%





Al momento que ejecute el código en python para que reconociera el banco de datos me dio los resultados anteriores, puedo decir que el porcentaje de fraude es bastante pequeño, constituyendo un 0.173% pero nos dio otro dato importante en cuales son las horas que más predominan los hacker o a que hora es que regularmente programan los fraudes.

Probabilidad y teorema de bayes

```
1. Probabilidad marginal P(Fraude): 0.001727 (0.173%)
2. P(Fraude | Monto > 100): 0.002301 (0.230%)
3. P(Fraude | Hora == 2): 0.017127 (1.713%)

--- APLICACIÓN DEL TEOREMA DE BAYES ---
Sensibilidad: 85.0% | Especificidad: 95.0%
4. P(Fraude | Alerta) = 0.0286 (2.86%)

Explicación de la Paradoja de la Tasa Base:
A pesar de tener un modelo con 95% de especificidad y 85% de sensibilidad, si salta una alerta,
la probabilidad real de que sea un fraude es solo del 2.86%. Esto ocurre porque
la tasa base de fraude es extremadamente baja (0.173%). La inmensa mayoría de las transacciones son
legítimas, por lo que ese pequeño 5% de falsos positivos inunda el sistema de alertas falsas.
```

Al aplicar el teorema de Bayes se descubrió el impacto de la paradoja de la tasa base. Supongamos que nuestro sistema tiene un 95% de especificidad y un 85% de sensibilidad para detectar anomalías. Si el sistema arroja una alerta, la probabilidad real de que sea un fraude es de apenas el 2.85%.

Esto ocurre porque la tasa base de fraude es extremadamente baja (0.173%). Como la inmensa mayoría de las transacciones son legítimas, lo que le representa al banco un alto costo operativo por bloquear tarjetas de clientes honestos.

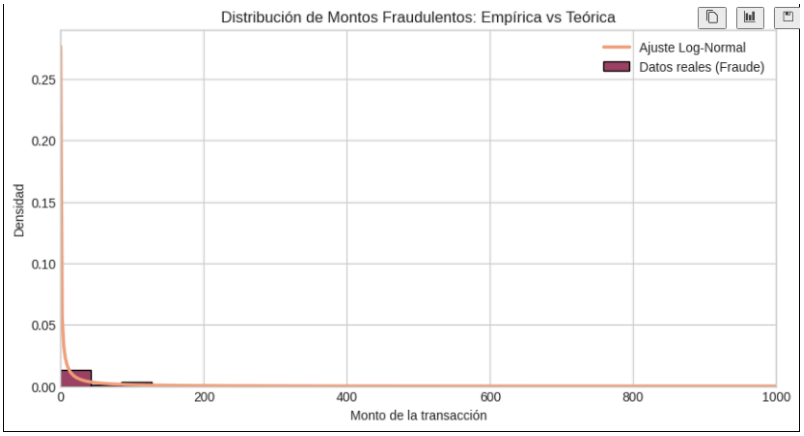
Variables aleatorias y momentos

```
--- MOMENTOS ESTADÍSTICOS DEL MONTO ('AMOUNT') POR CLASE ---

Legítima (0):
 Media (Esperanza empírica): 88.2910
 Varianza: 62552.5572
 Asimetría (Skewness): 17.0031
 Curtosis: 846.7370

Fraude (1):
 Media (Esperanza empírica): 122.2113
 Varianza: 65886.3105
 Asimetría (Skewness): 3.7545
 Curtosis: 17.7457

--- AJUSTE DE DISTRIBUCIÓN Y PÉRDIDA ESPERADA ---
Distribución ajustada: Log-Normal
Parámetros: shape=2.5543, scale=14.1624
Pérdida esperada teórica (E[X]): 369.7312
```



Los resultados nos dicen básicamente que la mayoría de las transacciones fraudulentas son por montos muy pequeños. Los estafadores suelen hacer micro transacciones para probar si una tarjeta robada está activa sin disparar las alertas del banco.

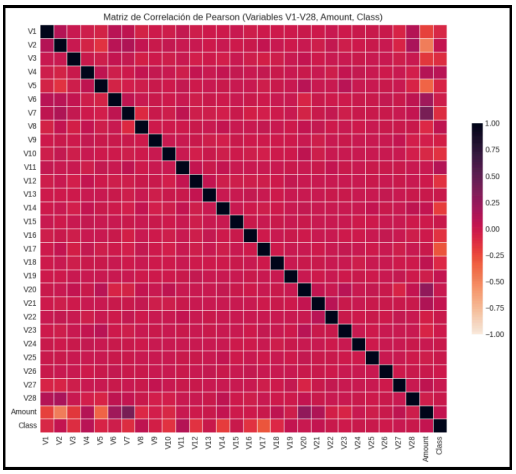
Independencia y Correlación

--- PRUEBA CHI-CUADRADO DE INDEPENDENCIA ---
Estadístico Chi-cuadrado: 674.4434
Valor p: 1.0660e-127
Conclusión: Rechazamos la hipótesis nula. Existe dependencia estadística entre la hora del día y la probabilidad de fraude.

Top 5 variables más correlacionadas con Fraude (Pearson):
V17 0.299371
V14 0.205613

V12 0.160534
V16 0.158727
V10 0.145086
Name: Class, dtype: float64

--- MATRICES DE CORRELACIÓN ---

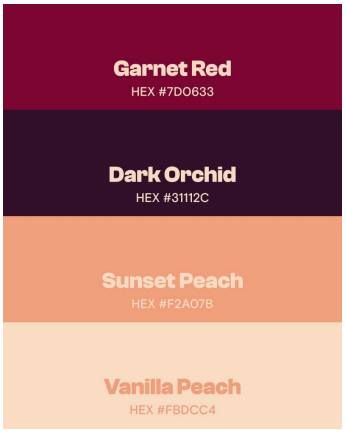


Como podemos ver las variables V1–V28 no se correlacionan entre sí por la naturaleza matemática ortogonal de la transformación PCA. Los resultados de la prueba Chi-Cuadrado nos comprueban la dependencia estadística entre la franja horaria y los ataques como pudimos observar en los gráficos anteriores.

Frontend Interactivo

Como inspiración use el tema de nostalgia digital, se me ocurrió hacer una página de tipo consola (o terminal) porque muchas veces cuando nos representan a los hackers en las películas o series siempre están trabajando en sistemas antiguos o bien hackeando desde la terminal.

Mi paleta de colores es esta:



M3: INDEPENDENCIA Y CORRELACION

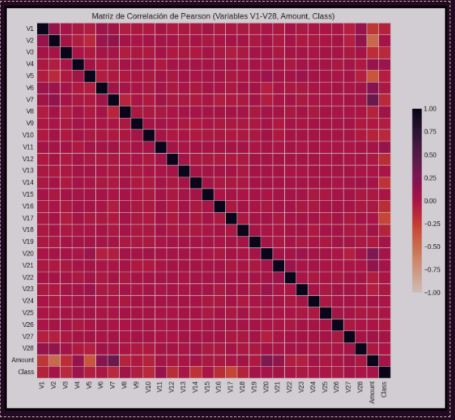
PRUEBA CHI-CUADRADO DE INDEPENDENCIA

> Estadistico Chi-Cuadrado: 674.4434
> Valor-P: 1.0660e-127

Conclusion: Rechazamos la hipotesis nula. Existe dependencia estadistica entre la hora del dia y la probabilidad de fraude.

MATRICES DE CORRELACION

Top 5 variables mas correlacionadas con fraude (Pearson):
V17 0.299371
V14 0.205613
V12 0.160534
V16 0.158727
V10 0.145086



M2: VARIABLES ALEATORIAS

ANÁLISIS DE MONTOS
(FRAUDE - 1)

> Esperanza empírica: €122.21
> Varianza: 65,886.31
> Asimetría (Skewness): 3.7545
> Curtosis: 17.7457

(LEGITIMA - 0)

> Esperanza empírica: €88.29
> Varianza: 62,552.56
> Asimetría (Skewness): 17.0031
> Curtosis: 846.7370

AJUSTE DE DISTRIBUCION Y PERDIDA ESPERADA

> Distribución ajustada: Log-Normal

PÉRDIDA ESPERADA (E[X]): €369.73



M1: PROBABILIDAD Y BAYES

PROBABILIDAD

> Probabilidad marginal: 0.001727 (0.173%)
> P(Fraude|Monto Alto > 100): 0.002301 (0.230%)
> P(Fraude|Franja Horaria == 2): 0.017127 (1.713%)

PARADOJA DE LA TASA BASE

> Sensibilidad del modelo: 85%
> Especificidad del modelo: 95%
> Tasa base real de fraude: 0.173%
> Teorema de Bayes (Fraude|Alerta): 0.0286 (2.86%)

> EXPLICACION DE LA PARADOJA DE LA TASA BASE:
A pesar de tener un modelo con 95% de especificidad y 85% de sensibilidad, si salta una alerta, la probabilidad real de que sea un fraude es extremadamente baja (0.173%). La inmensa mayoria de las transacciones son legitimas, por lo que ese pequeño 5% de falsos positivos inunda el sistema de alertas falsas.

ALERTA DEL SISTEMA: Debido a los falsos positivos, si salta una alerta, la probabilidad real de fraude es únicamente del 2.85%.

SISTEMA ANTIFRAUDE

ESTADO DEL SISTEMA: ONLINE

> Base de datos cargada: Credit Card Fraud Detection.

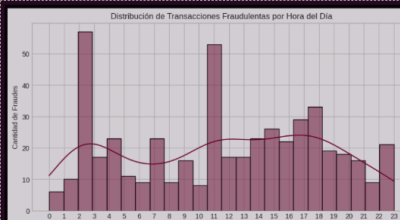
> Total de registros procesados: 284,807.

> Este es un dataset real (no sintetico) recolectado de transacciones de tarjetahabientes en Europa. Esta sumamente anonimizado mediante componentes principales (PCA) por lo que las ubicaciones exactas no son visibles, pero es el mejor para medir tasas de efectividad pura.

> Forma del dataset: (284807, 31)
> Valores nulos totales: 0
Distribución de clases:
0 284315
1 492
> Porcentaje de fraude: 0.173%



ADVERTENCIA: Las variables V1-V28 han sido transformadas mediante PCA por protocolos de seguridad.



INICIO | M1. PROBABILIDAD | M2. MOMENTOS | M3. INDEPENDENCIA

> SYS.ANTIFRAUDE.V2_

> AUTORIZACIÓN: KATHERINE SANTISTEBAN [ID: 1113-19-1584]
> ESTADO DE RED: SEGURO / EN LÍNEA

DATASET_SIZE: 284,807 REC.
FRAUD_RATE: 0.173%