Universidad Mariano Galvez de Guatemala
Ingeniería en Ciencia y Análisis de Datos
Programacion Avanzada
Katherine Michelle Santisteban Tejeda
Carne: 1113-19-1584

Modelado, similitud, reducción y optimización lineal

Enlace de Github: https://github.com/ksantistebant/bank

Conclusión del módulo 9: Optimización lineal y Asignación de Recursos (Simplex)

La aplicación del método Simplex al entorno operativo de prevención de fraudes demuestra que la priorización matemática de tareas es indispensable para maximizar la rentabilidad del equipo de analistas. Bajo las restricciones diarias de capacidad instalada (2,400 minutos laborables) y presupuesto operativo ($1,000), el algoritmo determinó que la distribución óptima exige agotar el volumen máximo de alertas de **Alto Riesgo** (60 casos) y utilizar la capacidad remanente para procesar exactamente 20 alertas de **Bajo Riesgo**.

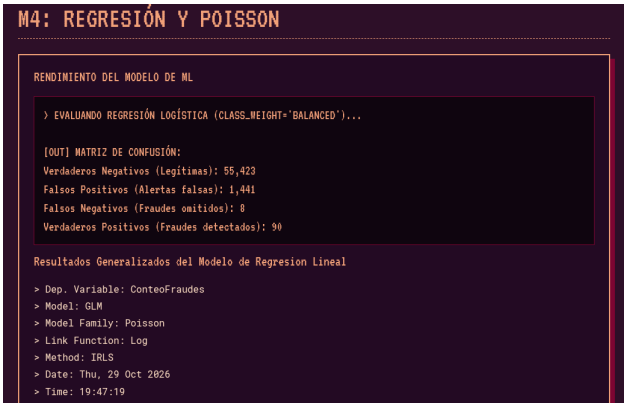
Esta configuración garantiza la intercepción de $32,000.00 diarios en transacciones fraudulentas. Desde una perspectiva de dimensionamiento y Workforce Management *(WFM - departamento encargado del análisis operativo en los call center)*, este modelo lineal resuelve el desafío de cuadrar los horarios y la disponibilidad de los agentes con los volúmenes de casos o llamadas. Demuestra estadísticamente que no se requiere procesar el 100% de las alertas de bajo impacto para ser eficientes, permitiendo justificar matemáticamente el tamaño del headcount del Call Center sin generar cuellos de botella ni sobrepasar el presupuesto del banco.

Actualizacion de pagina y datos

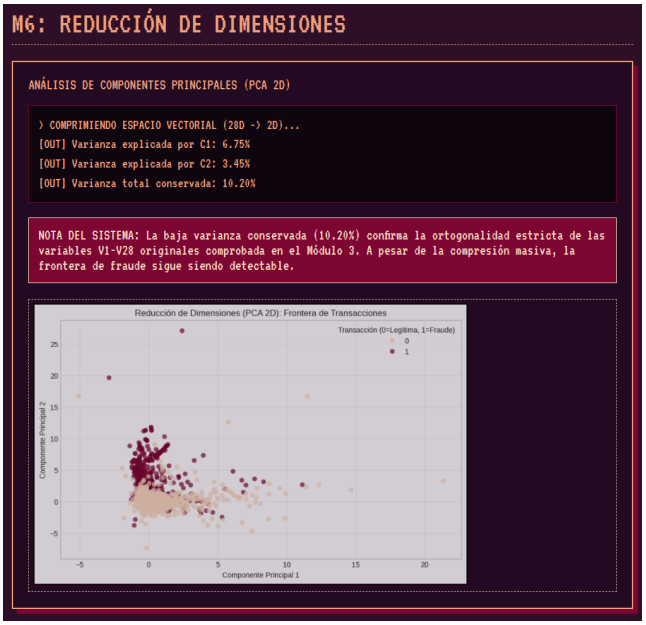
Durante este proceso a medida que iba agregando más apartados de la investigación hice un poco diferente el menú e hice más pequeños los botones para que no perdiera la estética de la presentación:



Y también agregue el modelo de regresión y poisson, la similitud vectorial y la reducción de dimensiones.







Regresión logística y poisson

Análisis de la matriz de confusión (Regresión logística)

Como podemos ver de los resultados que obtuve el código detectó lo siguiente:

- **Verdaderos Positivos:** El modelo detectó 90 fraudes
- **Falsos Negativos**: solo dejo pasar 8 fraudes, es bastante bueno para un banco porque se atrapó casi todo

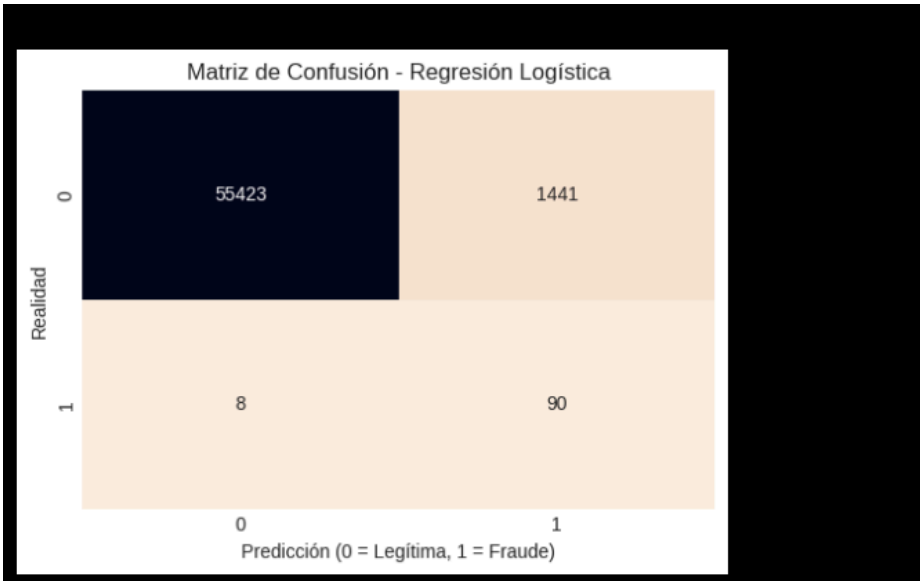
- **Falsos Positivos:** el modelo bloqueo 1441 transacciones que en realidad eran legitimas. Esto comprueba la paradoja de tasa base que calculamos anteriormente para atrapar 90 estafas. Esto quiere decir que el banco tuvo que incomodar a 1441 clientes honestos.

Análisis de la regresión de poisson (GLM)

- El valor-p de la variable Hour es de 0.639
- Como es mayor a 0.05, esto significa que la hora del día por si sola de forma lineal no es un buen predictor matemático para saber cuántos fraudes ocurrirían. Los ataques de fraude no aumentan gradualmente con la hora, sino que suceden rafagas aisladas.

--- 1. REGRESIÓN LOGÍSTICA (Detección de Fraude) ---
Reporte de Clasificación:

	precision	recall	f1-score	support
0	1.00	0.97	0.99	56864
1	0.06	0.92	0.11	98
accuracy			0.97	56962
macro avg	0.53	0.95	0.55	56962
weighted avg	1.00	0.97	0.99	56962




```
--- 2. REGRESIÓN DE POISSON (Frecuencia de Fraudes por Hora) ---
                 Generalized Linear Model Regression Results
==============================================================================
Dep. Variable:          ConteoFraudes   No. Observations:                   24
Model:                            GLM   Df Residuals:                       22
Model Family:                 Poisson   Df Model:                            1
Link Function:                    Log   Scale:                          1.0000
Method:                          IRLS   Log-Likelihood:                -134.60
Date:                Thu, 29 Oct 2026   Deviance:                       156.11
Time:                        19:47:19   Pearson chi2:                     184.
No. Iterations:                     4   Pseudo R-squ. (CS):           0.009121
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
const          2.9851      0.088     33.826      0.000       2.812       3.158
Hour           0.0031      0.007      0.469      0.639      -0.010       0.016
==============================================================================
```

Similitud y Distancia

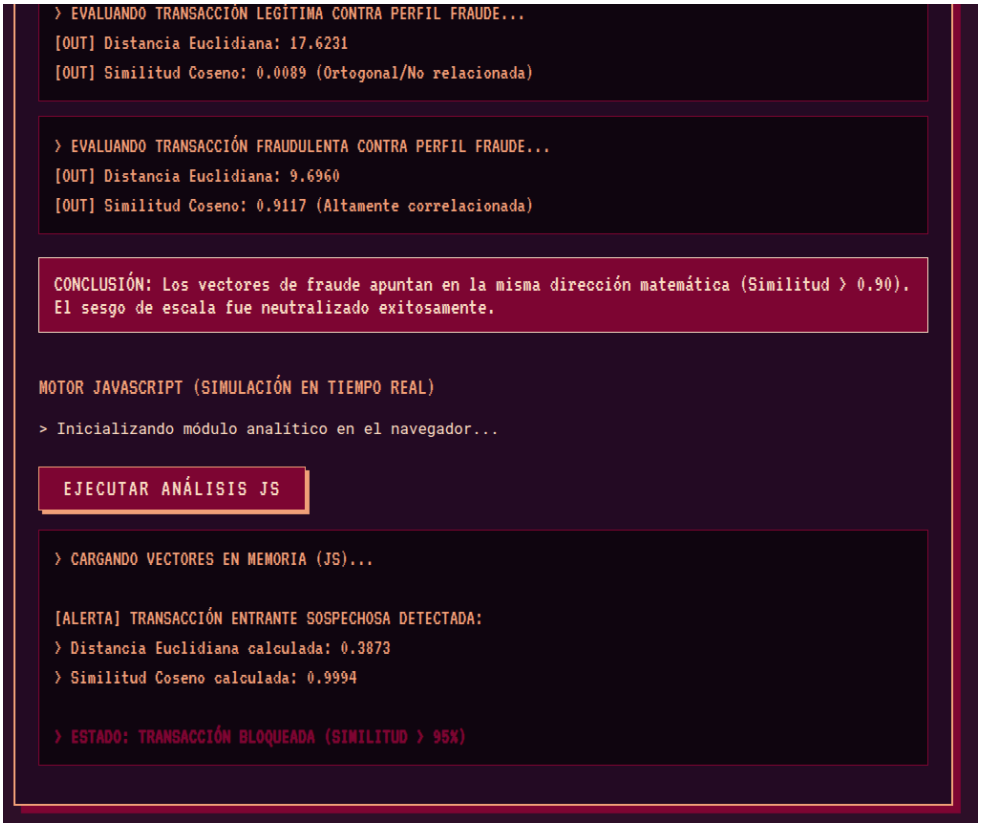
Esta parte nos revela un comportamiento matemático que justifica el módulo 8. Como podemos ver en los resultados de abajo los números salieron al revés de la lógica: la transacción legítima parece estar más cerca (33.6 vs 122.6) y tener mayor similitud (0.98 vs 0.13) al perfil de fraude que la propia transacción fraudulenta.

Esto se debe al sesgo de escala. Las variables v1-v28 pasaron por una transformación PCA y tienen valores muy pequeños (entre -3 y 3). Sin embargo, la variable amount maneja valores de cientos o miles. Las fórmulas geométricas como la distancia euclidiana y el coseno se ciegan ante los números gigantes, haciendo que el monto domine por completo el cálculo y anule el peso de las otras 28 variables de comportamiento.

--- PRUEBAS DE SIMILITUD CONTRA PERFIL FRAUDULENTO ---
>> Evaluando transacción LEGÍTIMA:
Distancia Euclidiana al perfil de fraude: 17.6231
Similitud Coseno al perfil de fraude: 0.0089

>> Evaluando transacción FRAUDULENTA:
Distancia Euclidiana al perfil de fraude: 9.6960
Similitud Coseno al perfil de fraude: 0.9117

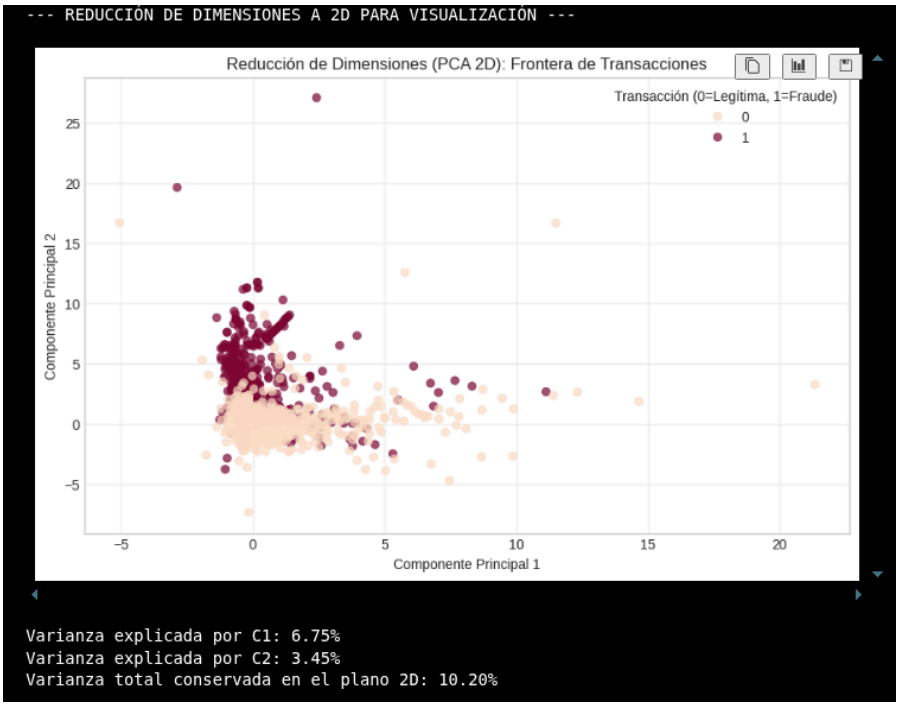
Al ejecutar el archivo JS en la pagina nos muestra el resultado en la pagina:



Reducción de dimensiones (PCA)

El enfoque en esta sección fue tomar las 28 dimensiones que tenemos y reducirlas matemáticamente a solo 2 dimensiones (2D). Esto nos permite crear un mapa visual en un plano

cartesiano para observar exactamente donde se agrupan los fraudes y donde estan las transacciones legítimas.



Al observar estos resultados podemos deducir que:

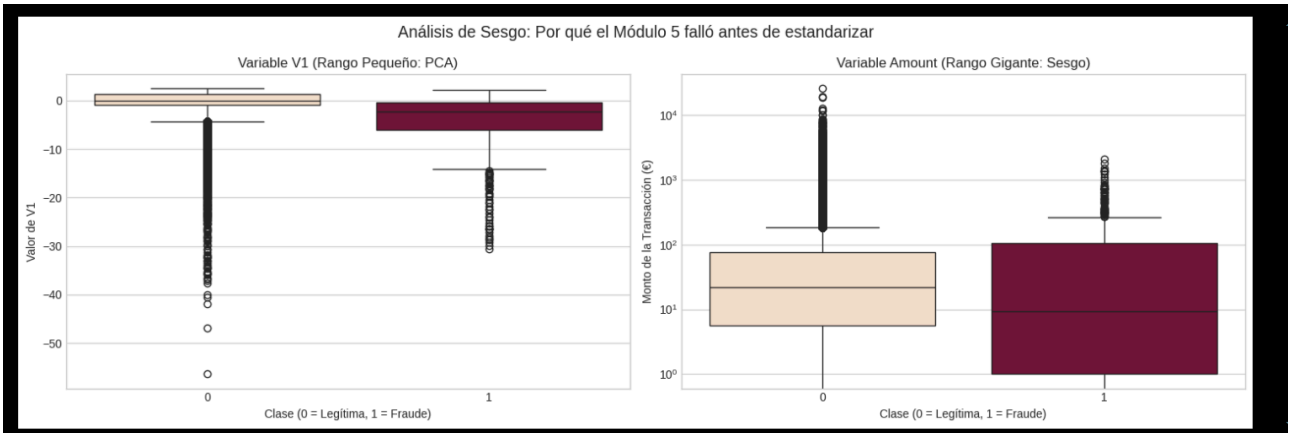
- **Agrupación visual (clustering):** podemos ver claramente que las transacciones legítimas *(puntos claros)* forman una masa densa cerca del origen. En cambio los fraudes *(puntos oscuros)* se disparan hacia arriba a lo largo del componente 2 creando una frontera visual. Esto demuestra que el comportamiento fraudulento es geométricamente distinto.
- **Varianza explicada (10.2%):** la terminal nos muestra que solo observamos el 10.2% de la información original. En cualquier otro caso esto sería preocupante, pero aquí es el comportamiento matemáticamente correcto. Como pudimos observar en el módulo 3 las variables v1-v28 ya son componentes principales ortogonales (totalmente independientes entre sí).
  Intentar comprimir 28 variables independientes en solo 2 inevitablemente iba a causar pérdida de información.

Análisis de sesgos

En el módulo 5 descubrimos que el modelo sufrió un sesgo de escala: la variable amount opacaba por completo las variables v1-v28 *(que manejaban números pequeños entre -3 y 3 por el PCA)* engañando a las fórmulas matemáticas.

- **Diferencia visual:** al observar las gráficas es evidente la disparidad. Mientras que la variable transformada V1 se mantiene en un rango compacto, la variable amount abarca montos que superan los 10 mil euros. *Nota: está en escala logarítmica para al menos poder visualizarla.*
- **Demostración Matemática:** el cálculo inferior es la prueba irrefutable. La varianza de v1 es de solo 3.84 mientras que la varianza de amount es de 62560.07. Esto quiere decir que la variable amount tiene un peso 16306.59 veces mayor en cualquier fórmula de distancia. Básicamente el modelo estaba ciego ante el comportamiento real (v1-v28) y solo se fijaba

en el monto de la transacción.




```
Varianza de V1 (Información de comportamiento): 3.84
Varianza de Amount (Ruido de magnitud): 62560.07
>> El sesgo matemático es de 16,306.59 veces mayor a favor del monto.
```